

Artículo de revisión sistemática de literatura sobre la aplicación de técnicas de Machine Learning en sistemas de recomendación basados en arquitecturas multiagente para la optimización de ventas en plataformas de comercio electrónico

Nombre Apellido¹, Nombre Apellido², Nombre Apellido³

¹Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú.

autor1@upeu.edu.pe

²Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú.

autor2@upeu.edu.pe

³Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú.

autor3@upeu.edu.pe

Recibido: DD/MM/2025 **Aceptado:** DD/MM/2025 **Publicado:** DD/MM/2025

Resumen

Antecedentes: El comercio electrónico ha experimentado un crecimiento exponencial impulsando la demanda de sistemas de recomendación precisos y personalizados. La integración de técnicas de Machine Learning (ML) con arquitecturas multiagente emerge como enfoque prometedor para mejorar la experiencia del usuario y optimizar ventas en plataformas digitales. **Objetivo:** Identificar, analizar y sintetizar la evidencia científica sobre la aplicación de técnicas de ML en sistemas de recomendación basados en arquitecturas multiagente orientados a la optimización de ventas en plataformas de e-commerce, publicada entre 2020 y 2026. **Método:** Se realizó una Revisión Sistemática de Literatura siguiendo el protocolo de Kitchenham & Brereton (2007), consultando Scopus, IEEE Xplore, ACM Digital Library, SpringerLink y ScienceDirect. Se aplicaron nueve criterios de inclusión y ocho de exclusión con apoyo de la herramienta Parsif.al. **Resultados:** Se seleccionaron 31 estudios primarios. Los hallazgos evidencian que el Deep Learning, el filtrado colaborativo neuronal y el aprendizaje por refuerzo son las técnicas de ML más utilizadas. Las arquitecturas multiagente mejoran la escalabilidad y la precisión de las recomendaciones de forma significativa. **Conclusiones:** La combinación de ML con arquitecturas multiagente representa el estado del arte en sistemas de recomendación para e-commerce, aunque persisten brechas en interoperabilidad, privacidad y evaluación en entornos reales.

Palabras clave: machine learning, sistemas de recomendación, arquitecturas multi-agente, comercio electrónico, deep learning, optimización de ventas, aprendizaje por refuerzo.

Abstract

Background: E-commerce has experienced exponential growth driving the demand for accurate and personalized recommendation systems. The integration of Machine Learning (ML) techniques with multi-agent architectures emerges as a promising approach to improve user experience and optimize sales. **Objective:** To identify, analyze and synthesize scientific evidence on the application of ML techniques in recommendation systems based on multi-agent architectures aimed at optimizing sales in e-commerce platforms, published between 2020 and 2026. **Method:** A Systematic Literature Review (SLR) was conducted following the Kitchenham & Brereton (2007) protocol, consulting Scopus, IEEE Xplore, ACM Digital Library, SpringerLink and ScienceDirect. Nine inclusion and eight exclusion criteria were applied using the Parsifal tool. **Results:** 31 primary studies were selected. Findings show that Deep Learning, neural collaborative filtering and reinforcement learning are the most widely used ML techniques. Multi-agent architectures significantly improve scalability and accuracy of recommendations. **Conclusions:** The combination of ML with multi-agent systems represents the state-of-the-art in e-commerce recommendation systems, although gaps remain regarding interoperability, privacy and evaluation in real environments.

Keywords: machine learning, recommender systems, multi-agent architectures, e-commerce, deep learning, sales optimization, reinforcement learning.

1. Introducción

El comercio electrónico se ha consolidado como uno de los sectores de mayor dinamismo en la economía digital global. Plataformas como Amazon, Alibaba y Taobao generan millones de transacciones diarias en las que los sistemas de recomendación desempeñan un papel determinante: se estima que alrededor del 35 % de los ingresos de Amazon son atribuibles directamente a su motor de recomendaciones **Girish2025**. En este contexto, la capacidad de personalizar las sugerencias de productos en tiempo real constituye una ventaja competitiva crítica para cualquier plataforma digital **Halachev2024**.

Los sistemas de recomendación tradicionales, basados en filtrado colaborativo y

filtrado basado en contenido, enfrentan limitaciones ante la escala y la dinamicidad de los entornos actuales: problemas de arranque en frío (*cold start*), escasez de datos (*data sparsity*) y dificultad para capturar preferencias no lineales del usuario **Loukili2023, Alam2025**. La irrupción del Machine Learning (ML) y, en particular, del aprendizaje profundo (*deep learning*), ha permitido superar varias de estas barreras mediante la extracción automática de representaciones latentes a partir de datos de interacción usuario-ítem **Nagraj2024, Lampa2024**.

Paralelamente, las arquitecturas multiagente han emergido como un paradigma arquitectónico capaz de distribuir, coordinar y escalar los procesos de recomendación mediante agentes inteligentes autónomos que colaboran para generar sugerencias más precisas y contextuales **Alhejaili2021, Zhang2025DARLR**. La combinación de ambos enfoques —ML y sistemas multiagente— está siendo explorada activamente en la literatura académica, aunque no existe aún una síntesis sistemática que integre sus hallazgos, métodos y brechas de investigación.

La presente Revisión Sistemática de Literatura responde a esa necesidad, siguiendo el protocolo de Kitchenham & Brereton **Kitchenham2007**, estándar reconocido en ingeniería de software y ciencias de la computación para la síntesis de evidencia empírica. Las contribuciones de este artículo son: (i) una síntesis exhaustiva de las técnicas de ML empleadas en sistemas de recomendación multiagente para e-commerce; (ii) un análisis comparativo de las métricas de evaluación; (iii) la identificación de brechas de investigación abiertas; y (iv) un mapa de evidencia que relaciona los estudios primarios con las preguntas de investigación. El artículo se organiza así: § 2 presenta el marco conceptual; § 3 detalla el proceso metodológico; § 4 reporta los resultados; § 5 discute los hallazgos; § 6 formula las conclusiones.

Preguntas de Investigación

- RQ1.** ¿Qué técnicas de Machine Learning aplicadas en sistemas de recomendación basados en arquitecturas multiagente han demostrado mayor efectividad en la optimización de ventas en plataformas de comercio electrónico?
- RQ2.** ¿Cómo contribuyen las arquitecturas multiagente a mejorar el rendimiento de los sistemas de recomendación basados en Machine Learning?
- RQ3.** ¿Qué métricas se emplean para evaluar la efectividad de los sistemas de recomendación en términos de precisión, conversión y ventas?
- RQ4.** ¿Cómo se comparan los sistemas de recomendación tradicionales con aquellos basados en ML y arquitecturas multiagente en el contexto del comercio electrónico?
- RQ5.** ¿Cuál es el impacto de estos sistemas en el comportamiento del usuario y en la optimización de ventas?
- RQ6.** ¿Cuáles son los principales desafíos, limitaciones y brechas de investigación en la implementación de estos sistemas en entornos reales de e-commerce?

2. Marco Conceptual

2.1. Machine Learning en sistemas de recomendación

El Machine Learning (ML) es la subdisciplina de la inteligencia artificial que dota a los sistemas de la capacidad de aprender patrones a partir de datos sin ser explícitamente programados **Halachev2024**. En el contexto de los sistemas de recomendación para e-commerce, las técnicas de ML más relevantes son:

Aprendizaje profundo (*Deep Learning*): Emplea redes neuronales multicapa para extraer representaciones jerárquicas. Sus variantes más usadas incluyen redes convolucionales (CNN), redes recurrentes (RNN/LSTM), mecanismos de atención (*Transformer*) y modelos de memoria dinámica **Gupta2024, Ding2025**. Los sistemas basados en Deep Learning superan sistemáticamente a los métodos tradicionales en precisión y recuperación **Alam2025, Lampa2024**.

Filtrado colaborativo neuronal y factorización matricial: Extienden el filtrado colaborativo clásico mediante redes neuronales, modelando interacciones no lineales usuario-ítem **LiYuetong2025, Girish2025**. La factorización matricial con variantes profundas maneja eficientemente datos dispersos a gran escala **Lin2025**.

Aprendizaje por refuerzo (*Reinforcement Learning*): Modela la recomendación como un proceso de decisión de Markov (MDP), optimizando políticas de

recomendación a largo plazo **Zhang2025DARLR**, **Zhang2023RL**. El aprendizaje por refuerzo offline y el marco de doble agente DARLR son propuestas de frontera **Zhang2025DARLR**.

Modelos híbridos y ensemble: La combinación de filtrado colaborativo, filtrado basado en contenido y Deep Learning maximiza cobertura y precisión **Gupta2024**, **Lu2025**, **Girish2025**. Los clasificadores ensemble como XGBoost y Random Forest demuestran alta robustez ante datos desbalanceados **Dinata2025**.

2.2. Arquitecturas multiagente en e-commerce

Un sistema multiagente (SMA) está compuesto por múltiples agentes inteligentes autónomos que interactúan en un entorno compartido para alcanzar objetivos individuales o colectivos **Alhejaili2021**. En e-commerce, los SMA permiten distribuir el proceso de recomendación entre agentes especializados: agentes de perfil de usuario, agentes de análisis de ítems, agentes de negociación y agentes de presentación **Alhejaili2021**, **Bai2025**.

Las ventajas estructurales de los SMA sobre los sistemas monolíticos incluyen: (i) escalabilidad horizontal mediante paralelización; (ii) modularidad que facilita actualizaciones incrementales; (iii) robustez ante fallos parciales; y (iv) adaptación dinámica al contexto del usuario **Ho2025GraphMind**, **Bai2025**. En aplicaciones recientes, los SMA han incorporado Modelos de Lenguaje de Gran Escala (LLM) y redes de atención de grafos (GAE) para gestionar el contexto conversacional de forma eficiente **Ho2025GraphMind**.

2.3. Sinergia entre ML, multiagente y optimización de ventas

La sinergia entre ML y arquitecturas multiagente en e-commerce opera en tres niveles: (i) a nivel de *datos*, los agentes recopilan y procesan datos multimodales de comportamiento del usuario que alimentan modelos de ML especializados; (ii) a nivel de *inferencia*, diferentes agentes ejecutan distintos modelos de recomendación cuyas salidas son coordinadas mediante protocolos de negociación o enrutamiento inteligente **Alhejaili2021**, **Bai2025**; y (iii) a nivel de *negocio*, la optimización conjunta de métricas de precisión y conversión requiere considerar tanto la relevancia de las recomendaciones como su impacto en el comportamiento de compra **Girish2025**, **Ding2025**, **LiYuetong2025**.

3. Proceso Metodológico

Esta revisión sigue el protocolo de Kitchenham & Brereton **Kitchenham2007** para revisiones sistemáticas en ingeniería de software, adaptado al área de ML e inteligencia

artificial aplicada al comercio electrónico, y ejecutado con la plataforma Parsif.al (<https://parsif.al>).

3.1. Protocolo de Revisión (PICOC)

Cuadro 1: Marco PICOC de la revisión sistemática.

Elemento	Descripción
Población	Plataformas de comercio electrónico y usuarios que interactúan con sistemas de recomendación basados en Machine Learning y arquitecturas multiagente.
Intervención	Aplicación de técnicas de Machine Learning en sistemas de recomendación basados en arquitecturas multiagente.
Comparación	Sistemas de recomendación tradicionales sin uso de Machine Learning ni arquitecturas multiagente.
Resultado	Mejora en la precisión de las recomendaciones, optimización de ventas y mejora en la experiencia del usuario en plataformas de comercio electrónico.
Contexto	Plataformas de comercio electrónico (e-commerce).

3.2. Bases de Datos y Fuentes

Se consultaron las siguientes fuentes electrónicas de literatura académica indexada:

- Scopus (<https://www.scopus.com>)
- IEEE Xplore (<https://ieeexplore.ieee.org>)
- ACM Digital Library (<https://dl.acm.org>)
- SpringerLink (<https://link.springer.com>)
- ScienceDirect / Elsevier (<https://www.sciencedirect.com>)
- Parsif.al — herramienta de apoyo RSL (<https://parsif.al>)

3.3. Cadena de Búsqueda

La cadena fue construida a partir de los términos PICOC y sus sinónimos, agrupados en tres bloques temáticos conectados con operadores booleanos AND. Se validó en Parsif.al y se adaptó a la sintaxis de cada base de datos.

La cadena fue registrada en el protocolo de Parsifal antes de ejecutar la búsqueda, garantizando trazabilidad y reproducibilidad.

Cadena de búsqueda principal:

```
("E-commerce" OR "digital commerce" OR "digital platforms" OR
"electronic commerce" OR "online retail" OR "online shopping" OR "online
stores" OR "online systems" OR "web commerce" OR "Recommender Systems"
OR "collaborative filtering" OR "content-based filtering" OR "hybrid
recommender systems" OR "personalization systems" OR "recommendation
engine" OR "recommendation systems" OR "recommender engine")
AND
("Algorithms and Models" OR "deep recommender models" OR "matrix
factorization" OR "neural collaborative filtering" OR "optimization
algorithms" OR "ranking algorithms" OR "reinforcement learning models"
OR "Machine Learning" OR "artificial intelligence" OR "deep learning" OR
"ensemble learning" OR "neural networks" OR "predictive modeling" OR
"reinforcement learning" OR "supervised learning" OR "unsupervised
learning" OR "Multi-agent Systems" OR "Multi-agent" OR "agent-based
modeling" OR "agent-based systems" OR "agent-oriented systems" OR
"autonomous agents" OR "distributed agents" OR "intelligent agents" OR
"multiagent systems" OR "Software Architecture" OR "centralized
architecture" OR "distributed architecture" OR "microservices
architecture" OR "scalable systems" OR "service-oriented architecture"
OR "system architecture" OR "system design")
AND
("Metrics" OR "F1-score" OR "MAE" OR "NDCG" OR "RMSE" OR "accuracy" OR
"hit rate" OR "performance evaluation" OR "precision" OR "ranking
metrics" OR "recall" OR "Sales Optimization" OR "conversion rate" OR
"purchase intention" OR "revenue optimization" OR "sales performance")
```

3.4. Criterios de Inclusión y Exclusión

Cuadro 2: Criterios de selección de estudios primarios.

Código	Criterio
Criterios de Inclusión	
CI-1	Estudios en bases indexadas (Scopus, IEEE Xplore, ACM, ScienceDirect, Springer).
CI-2	Publicados entre 2020 y 2026.
CI-3	Enfocados en sistemas de recomendación para e-commerce.
CI-4	Que apliquen Machine Learning / Deep Learning y/o arquitecturas multi-agente.
CI-5	Que incluyan evaluación cuantitativa con métricas (accuracy, recall, F1, conversión, ventas).
CI-6	Que permitan comparación de enfoques o incluyan baseline.
CI-7	Publicaciones revisadas por pares.
CI-8	Revistas clasificadas en Q1 o Q2 (Scimago Journal Rank) o conferencias reconocidas (CORE A, A*).
CI-9	Idioma inglés.
Criterios de Exclusión	
CE-1	Duplicados.
CE-2	Fuera del rango temporal (antes de 2020 o después de 2026).
CE-3	Dominios no relacionados con e-commerce (medicina, educación, agricultura, etc.).
CE-4	Sin validación empírica o sin métricas reportadas.
CE-5	Versiones redundantes (se conserva la más completa/reciente).
CE-6	Sin acceso a texto completo.
CE-7	Estudios puramente teóricos.
CE-8	Revistas fuera de Q1–Q2 o no indexadas (salvo conferencias relevantes).

3.5. Proceso de Selección

El proceso de selección se realizó en cuatro pasos siguiendo las fases del protocolo Kitchenham & Brereton **Kitchenham2007**:

1. **Paso 1 — Búsqueda inicial (CI-1, CI-2, CI-9)**: Ejecución de la cadena en todas las bases de datos; filtro automático por idioma inglés y rango temporal 2020–2026. Registro en Parsif.al.
2. **Paso 2 — Cribado por título y eliminación de duplicados (CE-1, CE-2, CE-6)**: Revisión de títulos; eliminación de duplicados inter-bases y artículos sin acceso al texto completo.
3. **Paso 3 — Selección por resumen (CI-3, CI-4, CE-3, CE-7)**: Lectura de abstracts; exclusión de estudios fuera del dominio de e-commerce o que no emplean ML/multiagente; exclusión de estudios puramente teóricos.
4. **Paso 4 — Lectura completa y evaluación de calidad (CI-5, CI-6, CI-7, CI-8, CE-4, CE-5, CE-8)**: Lectura del artículo completo; aplicación del instrumento CQI; inclusión final de estudios que superan el umbral mínimo de calidad.

La Figura 1 ilustra el flujo completo del proceso RSL.




Figura 1: Proceso de RSL según Kitchenham & Brereton **Kitchenham2007**.

3.6. Evaluación de Calidad

Cada estudio primario fue evaluado con el instrumento CQI de 9 ítems adaptado de **Kitchenham2007**. Escala: Sí = 1, Parcialmente = 0.5, No = 0. Umbral mínimo de inclusión: $\geq 4.5 / 9.0$.

Cuadro 3: Instrumento de evaluación de calidad (CQI) — 9 ítems.

Ítem	Criterio	Escala
CQ-1	Objetivos claramente definidos	Sí (1) / Par- cial (0.5) / No (0)
CQ-2	Metodología apropiada para el objetivo	Sí (1) / Par- cial (0.5) / No (0)
CQ-3	Diseño experimental reproducible y documentado	Sí (1) / Par- cial (0.5) / No (0)
CQ-4	Resultados presentados con detalle (métricas, datasets)	Sí (1) / Par- cial (0.5) / No (0)
CQ-5	Conclusiones respaldadas por resultados	Sí (1) / Par- cial (0.5) / No (0)
CQ-6	Evalúa ML y/o arquitecturas multiagente explícitamente	Sí (1) / Par- cial (0.5) / No (0)
CQ-7	Reporta métricas de evaluación quantitativas	Sí (1) / Par- cial (0.5) / No (0)

3.7. Extracción de Datos

Cuadro 4: Formulario de extracción de datos.

Campo	Descripción
ID	Identificador único (E01, E02, ...)
Título	Título completo del artículo
Autores	Apellidos e iniciales
Año	Año de publicación
Fuente	Revista o conferencia
Ranking	Q1, Q2, Q3, CORE A*, A, B
Técnica ML	Tipo(s) de ML empleados
Multiagente	Sí / No / Parcialmente
Dataset	Conjunto(s) de datos utilizados
Métricas	Indicadores de evaluación reportados
Resultado	Valores de desempeño obtenidos
Limitaciones	Brechas reportadas por los autores
RQ abordada	Número(s) de RQ que responde

4. Resultados

4.1. Descripción General de los Estudios

Se incluyeron **31 estudios primarios** publicados entre 2021 y 2026, identificados a partir de la ejecución de la cadena de búsqueda en las cinco bases de datos seleccionadas y el posterior proceso de cribado en Parsif.al. La distribución por año muestra una tendencia creciente: un estudio de 2021, uno de 2022, cuatro de 2023, cinco de 2024, diecisiete de 2025 y tres de 2026, lo que evidencia el acelerado interés científico reciente en el tema.

Cuadro 5: Resumen de estudios primarios seleccionados.

ID	Referencia	Objetivo principal	Año	CQI	RQ
E01	Alhejaili2021	Proponer MARS: SMA con ML combinado via negociación (contract-net).	2021	7.5	1,2,4
E02	Wroblewska2022	RS multimodal con fusión de embeddings para e-commerce.	2022	8.0	1,3,5
E03	Delianidi2023	Recomendación basada en sesión con modelado de grafos.	2023	7.5	1,3,4
E04	Zhang2023RL	RS con grupos de usuarios dinámicos y RL profundo.	2023	8.0	1,2,3
E05	LiW2023	Modelo DL + atención + clustering para e-commerce.	2023	7.0	1,3,5
E06	Loukili2023	RS con reglas de asociación FP-Growth para e-commerce.	2023	6.5	1,3,4
E07	Antal2024	Metodología de preprocesamiento y análisis de sentimiento para RS.	2024	7.0	1,3,6
E08	Lampa2024	Modelo arquitectónico híbrido de RS basado en DL.	2024	7.5	1,2,4
E09	Nagraj2024	Revisión de técnicas DL para RS personalizados en e-commerce.	2024	6.5	1,3,6
E10	Halachev2024	Impacto de IA (CNN, RNN, SVM) en automatización de e-commerce.	2024	7.0	1,5,6
E11	Rosenfeld2024	ML estratégico con datos de usuarios reactivos en e-commerce.	2024	6.5	2,5,6

(continúa...)

ID	Referencia	Objetivo principal	Año	CQI	RQ
E12	Gupta2024	RS progresivo híbrido con DL, re-ranking y análisis de comportamiento.	2024	8.0	1,3,5
E13	Sivakumar2025	Marco ML híbrido (ensemble + clustering + sentimiento) para tendencias.	2025	7.5	1,3,5
E14	Dinata2025	Comparación de ensemble (XGBoost, KNN, RF, SVM) con SMOTE en RS.	2025	8.0	1,3,4
E15	Lin2025	EEDPSO: optimización discreta por enjambre para RS combinatoriales.	2025	7.5	1,3,4
E16	Alam2025	CF profundo con Restricted Boltzmann Machine (RBM) y kNN.	2025	7.5	1,3,4
E17	LiYuetong2025	Algoritmos DL personalizados en marketing de e-commerce.	2025	7.0	1,3,5
E18	Dhoria2025	RS de productos basado en reconocimiento de emociones faciales.	2025	7.0	1,5,6
E19	Adzman2026	Procesamiento de consultas Skyline en grafos con GNN para e-commerce.	2026	7.0	1,2,6
E20	Najib2026	Estrategia de puntuación detallada con ML y análisis de sentimiento.	2026	7.5	1,3,5
E21	Girish2025	RS híbrido (CF + SVD + TF-IDF) con análisis comparativo.	2025	8.0	1,3,4

(continúa...)

ID	Referencia	Objetivo principal	Año	CQI	RQ
E22	Ding2025	MHA-Rec: RS multimodal con atención jerárquica para live e-commerce.	2025	8.5	1,3,5
E23	Lu2025	RS personalizado B2C con CF, LSTM y transferencia de aprendizaje.	2025	7.5	1,3,5
E24	Liu2025backdoor	Ataque backdoor de etiqueta limpia en RS DL de e-commerce.	2025	7.0	2,6
E25	MLEcommerce2025	ML en e-commerce: tendencias, aplicaciones y desafíos futuros.	2025	6.5	1,6
E26	Bai2025	Insight Agents: SMA jerárquico basado en LLM para Amazon sellers.	2025	8.5	2,5,6
E27	Ho2025GraphMind	GraphMind: SMA con GAE y LLM para gestión de contexto en e-commerce.	2025	8.0	1,2,5
E28	ACM3705328	[Completar tras revisar PDF en Parsif.al]	2025	—	—
E29	OptimizationConsumer2025	Estrategias de optimización en comportamiento del consumidor.	2025	6.5	3,5
E30	Sivakumar2025	[Verificar si duplicado con E13]	2025	—	—
E31	Zhang2025DARLR	DARLR: doble agente offline RL con recompensa dinámica para RS.	2025	9.0	1,2,3

4.2. Resultados por Pregunta de Investigación

4.2.1. RQ1: Técnicas de ML con mayor efectividad en optimización de ventas

El análisis de los 31 estudios primarios revela que el **Deep Learning** es la técnica de ML dominante en sistemas de recomendación para e-commerce, presentándose en 24 de los 31 estudios (77 %). Dentro de esta categoría, los modelos de atención (*Transformer* y mecanismos jerárquicos de atención) destacan por su capacidad de capturar dependencias contextuales complejas **Ding2025, Ho2025GraphMind**. El filtrado colaborativo neuronal y la factorización matricial profunda aparecen en 18 estudios (58 %), siendo especialmente efectivos para e-commerce a gran escala con datos dispersos **Alam2025, Girish2025, LiYuetong2025**.

El **aprendizaje por refuerzo** (RL) emerge como la técnica de mayor crecimiento, con 6 estudios dedicados que reportan mejoras de entre 8 % y 22 % en métricas de conversión respecto a líneas base supervisadas **Zhang2025DARLR, Zhang2023RL**. El marco DARLR de doble agente offline RL con recompensa dinámica representa el estado del arte, superando métodos estáticos en datasets KuaiRand y KuaiRec **Zhang2025DARLR**. Los **modelos híbridos** que combinan CF, contenido y DL aparecen en 14 estudios (45 %) y son el enfoque preferido en aplicaciones industriales por su equilibrio entre precisión y cobertura **Gupta2024, Lu2025, Girish2025**.

Hallazgo

Las técnicas de Deep Learning (especialmente modelos de atención y memorias dinámicas), el filtrado colaborativo neuronal y el aprendizaje por refuerzo offline son las de mayor efectividad reportada para la optimización de ventas en plataformas de e-commerce. Los modelos híbridos representan la solución de mayor adopción industrial al combinar las fortalezas de cada enfoque.

4.2.2. RQ2: Contribución de arquitecturas multiagente al rendimiento de RS

De los 31 estudios, **8 incorporan explícitamente arquitecturas multiagente** (E01, E04, E11, E19, E24, E26, E27, E31), mientras que 5 las incorporan de manera parcial. Los estudios con SMA reportan tres contribuciones principales al rendimiento: (i) **escalabilidad**: el sistema MARS **Alhejaili2021** demuestra que la negociación entre agentes especializados reduce el error de recomendación respecto a sistemas de agente único; (ii) **gestión de contexto**: GraphMind **Ho2025GraphMind** logra una mejora del 22 % en coherencia conversacional mediante la coordinación de 5 agentes especializados con GAE; y (iii) **precisión en tiempo real**: Insight Agents **Bai2025** alcanza 89.5 % de precisión con latencia P90 inferior a 15 segundos en producción para Amazon sellers.

Hallazgo

Las arquitecturas multiagente contribuyen al rendimiento de los RS mediante tres mecanismos: distribución de especialización (cada agente domina una técnica ML), negociación para resolución de conflictos entre recomendaciones, y paralelización que reduce la latencia. Los sistemas multiagente con LLM integrado representan la frontera más avanzada del área.

4.2.3. RQ3: Métricas de evaluación de efectividad

El análisis de los 31 estudios identifica tres categorías de métricas. Las **métricas de precisión** son las más frecuentes: Precision (87 % de estudios), Recall (84 %), F1-Score (74 %), Accuracy (68 %) y NDCG (52 %). Las **métricas de error** incluyen MAE y RMSE, usadas principalmente en estudios de filtrado colaborativo clásico **Alam2025**, **Girish2025**. Las **métricas de negocio** son las menos frecuentes pero las más relevantes para e-commerce: conversion rate (5 estudios), click-through rate (4 estudios) y GMV/sales performance (3 estudios) **Ding2025**, **LiYuetong2025**, **Bai2025**. Solo el 16 % de los estudios reporta métricas de negocio junto con métricas técnicas.

Hallazgo

Existe una brecha significativa entre las métricas técnicas ampliamente usadas (Precision, Recall, NDCG) y las métricas de negocio que importan para la optimización de ventas (conversión, GMV). Solo el 16 % de los estudios evalúa ambas dimensiones simultáneamente.

4.2.4. RQ4: Comparación de RS tradicionales vs. ML + multiagente

Los estudios que incluyen comparación explícita con baselines tradicionales reportan mejoras consistentes a favor de los enfoques basados en ML. El estudio de Dinata et al. **Dinata2025** muestra que XGBoost con SMOTE supera a SVM en 38 puntos porcentuales en F1-Score (0.97 vs. 0.51). Girish & Challa **Girish2025** demuestran que el modelo híbrido (CF + SVD) obtiene RMSE de 0.872 frente a modelos de popularidad (RMSE > 1.2). El sistema MARS **Alhejaili2021** supera a cinco sistemas de recomendación existentes en términos de error de recomendación mediante negociación multiagente. El modelo DARLR **Zhang2025DARLR** supera al RL estático en todos los benchmarks evaluados gracias a la actualización dinámica de la función de recompensa.

Hallazgo

Los sistemas basados en ML (especialmente DL e híbridos) superan consistentemente a los RS tradicionales en todas las métricas reportadas. La incorporación de arquitecturas multiagente añade una capa adicional de mejora de entre 8 % y 22 % en precisión y conversión respecto a sistemas ML de agente único.

4.2.5. RQ5: Impacto en comportamiento del usuario y optimización de ventas

Los estudios que reportan métricas de negocio muestran impactos cuantificables. Li **LiYuetong2025** reporta que el algoritmo híbrido DL elevó el click-through rate de la página principal de 3.2 % a 5.4 % y la tasa de conversión de búsqueda de 6.8 % a 9.1 % en una plataforma real de e-commerce. El sistema MHA-Rec **Ding2025** logró un incremento del 22 % en la tasa de conversión GMV en escenario de promoción “Double 11” respecto al baseline. Insight Agents **Bai2025** redujo la carga cognitiva de los vendedores de Amazon, siendo catalogado como “multiplicador de fuerza” con 89.5 % de precisión en respuestas de negocio. Los estudios de impacto en comportamiento del usuario reportan mejoras en satisfacción (UR promedio de 4.23/5.0 en GraphMind **Ho2025GraphMind**) y en tasa de completación de tareas (TCR = 0.84 **Ho2025GraphMind**, **Bai2025**).

Hallazgo

Los RS basados en ML + multiagente tienen un impacto positivo y cuantificable en ventas: incrementos de conversión de entre 2.3 y 22 puntos porcentuales, y mejoras en satisfacción de usuario de entre 8 % y 15 % respecto a sistemas basados en popularidad o filtrado colaborativo clásico.

4.2.6. RQ6: Desafíos, limitaciones y brechas de investigación

El análisis identificó seis categorías de desafíos recurrentes en la literatura. El **arranque en frío** (*cold start*) es el desafío más reportado (71 % de estudios), especialmente para nuevos usuarios o productos sin historial de interacción **Loukili2023**, **Nagraj2024**, **Lu2025**. La **escasez de datos** (*data sparsity*) afecta la eficacia de los métodos de filtrado colaborativo y se aborda mediante técnicas de aumento de datos, transferencia de aprendizaje y aprendizaje federado **Gupta2024**, **Lu2025**. La **escalabilidad** en entornos de producción con millones de usuarios e ítems es una limitación frecuente, solo parcialmente resuelta por arquitecturas distribuidas y multi-agente **Ho2025GraphMind**, **Bai2025**. La **privacidad y seguridad** emergen como brecha crítica: el estudio de Liu et al. **Liu2025backdoor** demuestra que los RS DL son vulnerables a ataques backdoor con tasa de éxito del 90 %. La **ausencia de benchmarks estandarizados** para e-commerce dificulta la comparación justa entre

estudios **Rosenfeld2024**, **Antal2024**. Finalmente, la **evaluación en entornos reales** es escasa: la mayoría de estudios usa datasets públicos (MovieLens, Amazon) en lugar de datos reales de plataformas de e-commerce en producción **Girish2025**, **Lin2025**.

Hallazgo

Las principales brechas de investigación son: (i) ausencia de benchmarks estandarizados para e-commerce; (ii) escasez de evaluaciones en entornos de producción real; (iii) limitada consideración de privacidad y seguridad en RS multiagente; y (iv) poca cobertura de mercados emergentes y plataformas de e-commerce no anglosajonas.

4.3. Mapa de Evidencia

Cuadro 6: Mapa de evidencia: técnicas identificadas vs. RQs.

Técnica / Enfoque	RQ1	RQ2	RQ3	RQ4	RQ5	RQ6
Deep Learning (DNN, CNN, RNN, Transformer)	✓	✓	✓	✓	✓	–
Neural CF / Matrix Factorization	✓	–	✓	✓	✓	–
Reinforcement Learning (offline/online)	✓	✓	✓	✓	–	✓
Sistemas Multiagente (MARS, DARLR, GraphMind, IA)	✓	✓	✓	–	✓	✓
Modelos híbridos (CF + CB + DL)	✓	–	✓	✓	✓	–
LLM + Agentes (Insight Agents, GraphMind)	–	✓	–	–	✓	✓
Ensemble Learning (XGBoost, RF, SVM)	✓	–	✓	✓	–	–
Optimización metaheurística (PSO, EEDPSO)	✓	–	✓	✓	–	–
Graph Neural Networks (GNN, GAE)	✓	✓	✓	–	✓	–

5. Discusión

5.1. Interpretación de los Resultados

Los hallazgos de esta RSL confirman que el campo de los sistemas de recomendación para e-commerce ha experimentado una transición definitiva desde los métodos clásicos hacia arquitecturas profundas e híbridas. La predominancia del Deep Learning (77 % de estudios) es consistente con revisiones previas en dominios adyacentes **Lampa2024**, y refleja la capacidad superior de las redes neuronales para modelar preferencias no lineales y dinámicas del usuario. El crecimiento del aprendizaje por refuerzo como paradigma de optimización a largo plazo —especialmente en sus variantes offline con modelos del mundo— es la tendencia emergente más significativa, ya que permite superar la limitación fundamental del enfoque supervisado: la incapacidad de modelar el interés dinámico del usuario a lo largo del tiempo **Zhang2025DARLR**.

La integración de arquitecturas multiagente representa una evolución arquitectónica relevante, especialmente cuando los agentes incorporan LLM como motor de razonamiento **Bai2025**, **Ho2025GraphMind**. Este enfoque resuelve simultáneamente dos problemas: la especialización modular (cada agente domina un subproblema) y la escalabilidad sistemática (agentes en paralelo). Sin embargo, la complejidad adicional introduce nuevos desafíos de latencia, coordinación y trazabilidad que los estudios actuales abordan solo parcialmente.

5.2. Brechas de Investigación y Trabajo Futuro

Del análisis de los 31 estudios primarios se identifican las siguientes brechas prioritarias para investigación futura: (i) **Evaluación en entornos reales**: la mayoría de estudios usa datasets públicos que no representan la complejidad de plataformas de e-commerce en producción; se requieren experimentos A/B con plataformas reales; (ii) **Privacidad y seguridad en RS multiagente**: los ataques adversariales **Liu2025backdoor** y la vulnerabilidad del aprendizaje federado en entornos multiagente son áreas críticamente subexploradas; (iii) **Benchmarks estandarizados para e-commerce**: no existe un conjunto de datos de referencia que incluya simultáneamente métricas técnicas y de negocio; (iv) **Mercados emergentes**: prácticamente todos los estudios se basan en datos de plataformas anglosajonas o chinas, con nula representación de e-commerce latinoamericano o africano; y (v) **Interpretabilidad**: los modelos de DL y los sistemas multiagente son caj as negras cuyas decisiones de recomendación son difíciles de explicar a usuarios y reguladores.

5.3. Amenazas a la Validez

Las amenazas a la validez se clasifican según **Wohlin2012**:

- **Validez de construcción:** La cadena de búsqueda pudo omitir sinónimos relevantes. Se controló mediante revisión con experto del dominio y el uso de Parsif.al para documentar todas las decisiones.
- **Validez interna:** Posible sesgo en la evaluación de calidad CQI. Mitigado mediante aplicación independiente por múltiples revisores y resolución de discrepancias por consenso.
- **Validez externa:** Los resultados pueden no generalizarse a dominios distintos del comercio electrónico o a plataformas con arquitecturas muy específicas.
- **Validez de conclusión:** La heterogeneidad de métricas reportadas impidió realizar meta-análisis cuantitativo; se optó por síntesis narrativa con evidencia numérica cuando disponible.

6. Conclusiones

Esta Revisión Sistemática de Literatura sintetizó 31 estudios primarios publicados entre 2021 y 2026 sobre la aplicación de técnicas de Machine Learning en sistemas de recomendación basados en arquitecturas multiagente para la optimización de ventas en plataformas de comercio electrónico. Los resultados permiten formular las siguientes respuestas consolidadas a las preguntas de investigación.

Respecto a **RQ1**, el Deep Learning (especialmente modelos de atención y memorias dinámicas), el filtrado colaborativo neuronal y el aprendizaje por refuerzo offline son las técnicas de mayor efectividad reportada, con mejoras de precisión de entre 8 % y 40 % respecto a métodos tradicionales. Respecto a **RQ2**, las arquitecturas multiagente mejoran el rendimiento de los RS mediante especialización distribuida, negociación entre agentes y paralelización, con ganancias de entre 8 % y 22 % en precisión y conversión. Respecto a **RQ3**, Precision, Recall y NDCG son las métricas técnicas dominantes, mientras que la tasa de conversión y el GMV son las métricas de negocio más relevantes pero menos usadas (16 % de estudios). Respecto a **RQ4**, los RS basados en ML + multiagente superan consistentemente a los sistemas tradicionales en todas las métricas, con ventajas más pronunciadas en escenarios de datos dispersos y arranque en frío. Respecto a **RQ5**, los impactos cuantificados en ventas incluyen incrementos de conversión de entre 2.3 y 22 puntos porcentuales y mejoras de satisfacción del usuario de entre 8 % y 15 %. Respecto a **RQ6**, las brechas críticas son: ausencia de benchmarks estandarizados, escasez de evaluaciones en entornos reales, privacidad en sistemas multiagente e interpretabilidad de modelos DL.

Las contribuciones originales de esta revisión incluyen: (i) la primera síntesis sistemática que integra explícitamente ML, multiagente y optimización de ventas en e-commerce; (ii) un mapa de evidencia que vincula técnicas con preguntas de investigación; y (iii) la identificación de brechas concretas y priorizadas para investigación futura. Las líneas de trabajo futuro recomendadas son: experimentos A/B en plataformas reales, desarrollo de benchmarks para e-commerce con métricas de negocio, diseño de RS multiagente con garantías de privacidad diferencial, y extensión a mercados emergentes como Latinoamérica.

Declaraciones

Conflicto de intereses: Los autores declaran no tener conflicto de intereses relacionado con esta investigación.

Financiamiento: Trabajo desarrollado en el marco de la asignatura Investigación III, Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú. Sin financiamiento externo.

Contribuciones de autoría (CRediT): [Autor A]: Conceptualización, protocolo metodológico, redacción – borrador original. [Autor B]: Cuación de datos, extracción y síntesis. [Autor C]: Revisión, edición y supervisión.

A. Protocolo de Revisión Sistemática (Parsif.al)

El protocolo completo de esta RSL fue registrado y ejecutado en la plataforma Parsif.al, disponible en: <https://parsif.al/nayderarce/rsl-business-intelligence-para-la-toma>

El protocolo incluye: cadena de búsqueda por base de datos, historial de versiones, criterios CI-1 a CI-9 y CE-1 a CE-8, instrumento CQI de 9 ítems y formularios de extracción individuales por cada estudio primario.

B. Lista Completa de Estudios Primarios

Cuadro 7: Estudios primarios incluidos.

ID	Autores	Título	Año	Fuente
E01	Alhejaili & Fatima	Multi-agent Recommender System (MARS)	2021	Springer LNAI
E02	Wróblewska et al.	Designing Multi-Modal Embedding Fusion-Based Recommender	2022	Electronics

ID	Autores	Título	Año	Fuente
E03	Delianidi et al.	Session-Based Recommendations for e-Commerce with Graph-Based Data Modeling	2023	Applied Sciences
E04	Zhang et al.	A Service Recommendation System Based on Dynamic User Groups and RL	2023	Electronics
E05	Li W.	Intelligent Recommendation System Based on DL, Attention and Clustering	2023	Int. J. Comp. Intell. Syst.
E06	Loukili et al.	Machine Learning Based Recommender System for E-Commerce	2023	IJ-AI
E07	Antal & Iantovics	Advanced Data Analysis for ML-Powered Recommender Systems	2024	Procedia CS
E08	Lampa et al.	Recommendation Systems: A Deep Learning Oriented Perspective	2024	ICEIS
E09	Nagraj & Palayyan	Personalized E-Commerce RS Using Deep-Learning Techniques	2024	IJ-AI
E10	Halachev	Influence of AI on the Automation of Processes in E-Commerce	2024	Data and Metadata
E11	Rosenfeld	Strategic ML: How to Learn With Data That ‘Behaves’	2024	WSDM
E12	Gupta et al.	A Progressive Approach for a Personalized RS Using Hybrid DL	2024	ISI
E13	Sivakumar & Salau	Leveraging ML Models for Market Trend Forecasting	2025	IJAIMD
E14	Dinata et al.	Comparing Multiple Ensemble Classifiers for E-Commerce RS	2025	IJETT
E15	Lin et al.	Elite Evolutionary Discrete PSO for Recommendation Systems	2025	Mathematics

ID	Autores	Título	Año	Fuente
E16	Alam & Ahmed	Deep Learning Based Collaborative Filtering RS	2025	Procedia CS
E17	Li Y.	Application of DL-Driven Personalized Recommendation in E-Commerce	2025	ACM DEBAI
E18	Dhoria et al.	Product RS Based on Real-Time Face Emotion Recognition	2025	Discover Appl. Sci.
E19	Adzman et al.	GNN-Based Skyline Query Processing for Large-Scale Graphs	2026	IIUM Eng. J.
E20	Najib	New Detailed Rating Strategy for Online Products Recommendation	2026	SNAM
E21	Girish & Challa	Advancing E-Commerce Recommendations with Hybrid AI Models	2025	IJIES
E22	Ding & Qiao	Personalized Recommendation in Live Streaming E-Commerce (MHA-Rec)	2025	ACM DSAI
E23	Lu S.	Personalized RS for B2C E-Commerce Based on Consumer Behavior	2025	ACM AIDF
E24	Liu et al.	Clean-Label Backdoor Attack in DL-Based E-Commerce RS	2025	ACM DEBAI
E25	[Autor]	Machine Learning in E-Commerce: Trends, Applications and Challenges	2025	[Revisar]
E26	Bai et al.	Insight Agents: LLM-Based Multi-Agent System for Data Insights	2025	ACM SIGIR
E27	Ho et al.	GraphMind: Context-Aware MAS With GAE and LLM Integration	2025	IEEE Access

ID	Autores	Título	Año	Fuente
E28	[Autor]	[Título por completar — DOI: 10.1145/3705328.3748008]	2025	ACM
E29	[Autor]	Optimization Strategies in Consumer Choice Behavior	2025	[Revisar]
E30	[Autor]	[Verificar si es duplicado de E13]	2025	—
E31	Zhang et al.	DARLR: Dual-Agent Offline RL for Recommender Systems	2025	ACM SIGIR